

Metodología detallada: formulación matemática del pipeline

Descripción completa, etapa por etapa, de lo que calcula `codigo/Descriptores_Final.m`. Usa la notación de la tesis (E , T , E_{seg} , M_L , M_G , M_R , M_e , M_{mor} , E_B) y está pensada como base para reescribir el Capítulo 3.

El comportamiento interno de `adaptthresh` (factor de umbral y núcleo gaussiano) se verificó con el código fuente de MATLAB (`edit adaptthresh`) y una prueba numérica.

0. Notación y parámetros

Símbolo	Significado	Valor
$N \times N$	tamaño de imagen	1024×1024 px
L	lado físico del barrido	$60 \mu\text{m}$
Δ	resolución espacial L/N	58.59 nm/px
(i, j)	fila i (eje y , hacia abajo), columna j (eje x)	—
s	sensibilidad de la binarización adaptativa	0.55
n_L, n_R	parámetro <code>NeighborhoodSize</code> local / regional (actúa como σ del núcleo gaussiano, ver 6.1)	21 px / 51 px
K	número de umbrales de Otsu multinivel	6 ($\rightarrow$ 7 clases)
$A_{\min}$	área mínima por componente conexa	50 px
c_{fb}	cobertura mínima antes del respaldo	0.15
r	radio del cierre morfológico	3 px ($\approx 176 \text{ nm}$)
k_{spur}	iteraciones de poda del esqueleto	5
w	ventana RLOESS	50 filas
α	umbral de longitud para CNTA	2000 nm
σ_d, σ_i	escalas del tensor de estructura	2 px / 8 px

Estadísticos robustos usados a lo largo del pipeline, para un conjunto de valores $\{x\}$:

$$\text{med}(x) = \text{mediana}, \quad \text{MAD}(x) = \text{med}(|x - \text{med}(x)|), \quad P_q(x) = \text{percentil } q.$$

Conectividad: todas las componentes conexas se definen con vecindad de 8.

1. Adquisición

Cada archivo `.ibw` contiene varios canales del barrido KPFM. Se usan:

- **Canal eléctrico** E_{raw} (canal 5): amplitud del segundo armónico, $\propto \partial C / \partial z$, en metros calibrados por el sistema.
- **Canal topográfico** T_{raw} (canal 1): altura de la superficie.

Ambos se rotan 90° (`rot90`) para orientar la dirección rápida de barrido en horizontal, de modo que **cada fila i corresponde a una línea de barrido**. Si los tamaños difieren, E_{raw} se reinterpola al tamaño de T_{raw} .

El nombre del archivo `[V][f]-[n].ibw` codifica la fabricación:

Código	Voltaje	Código	Frecuencia
0	5 V	a	10 Hz
1	10 V	b	1 kHz
2	15 V	c	100 kHz

Con la imagen $n \in \{1, \dots, 9\}$: réplica = $\lceil n/3 \rceil$, posición = $((n - 1) \bmod 3) + 1$.

2. Corrección de crosstalk topográfico

2.1 Normalización robusta

Ambos canales se llevan a una escala adimensional comparable:

$$\tilde{E} = \frac{E_{raw} - \text{med}(E_{raw})}{\text{MAD}(E_{raw})}, \quad \tilde{T} = \frac{T_{raw} - \text{med}(T_{raw})}{\text{MAD}(T_{raw})}.$$

Se usan la mediana y la MAD en lugar de media y desviación estándar porque no se ven afectadas por los valores extremos (rayones, saltos de la punta) presentes en los datos.

2.2 Modelo de regresión

Las derivadas direccionales de la topografía se calculan con diferencias centrales (diferencias de un lado en los bordes):

$$\frac{\partial \tilde{T}}{\partial x}(i, j) \approx \frac{\tilde{T}(i, j + 1) - \tilde{T}(i, j - 1)}{2}, \quad \frac{\partial \tilde{T}}{\partial y}(i, j) \approx \frac{\tilde{T}(i + 1, j) - \tilde{T}(i - 1, j)}{2}.$$

Se plantea un único modelo lineal **para toda la imagen**:

$$\tilde{E}(i, j) = \beta_0 + \beta_1 \tilde{T}(i, j) + \beta_2 \frac{\partial \tilde{T}}{\partial x}(i, j) + \beta_3 \frac{\partial \tilde{T}}{\partial y}(i, j) + \varepsilon(i, j).$$

Apilando los N^2 píxeles como filas, $\mathbf{e} = \text{vec}(\tilde{E}) \in \mathbb{R}^{N^2}$ y

$$\mathbf{X} = \begin{bmatrix} \text{vec}(\tilde{T}) & \text{vec}(\partial_x \tilde{T}) & \text{vec}(\partial_y \tilde{T}) & \mathbf{1} \end{bmatrix} \in \mathbb{R}^{N^2 \times 4},$$

los coeficientes se obtienen por mínimos cuadrados ordinarios:

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \|\mathbf{e} - \mathbf{X}\boldsymbol{\beta}\|_2^2 = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{e}.$$

(En MATLAB `X \ e`, resuelto por factorización QR.)

2.3 Sustracción

La componente explicada por la topografía, $\hat{E}_T = \mathbf{X}\hat{\boldsymbol{\beta}}$, se resta **píxel a píxel**:

$$E_{corr}(i, j) = \tilde{E}(i, j) - \hat{E}_T(i, j).$$

Lo que se resta es un mapa completo, distinto en cada píxel, no una constante global ni por fila.

2.4 Propiedades

Por construcción de mínimos cuadrados, el residuo es ortogonal a cada columna de $\mathbf{X}$:

$$\mathbf{X}^\top \text{vec}(E_{corr}) = \mathbf{0}.$$

Como $\mathbf{X}$ incluye la columna de unos, E_{corr} tiene media cero y **covarianza (y correlación de Pearson) exactamente nula** con $\tilde{T}$, $\partial_x \tilde{T}$ y $\partial_y \tilde{T}$. Por eso la correlación eléctrico-topográfica posterior a la corrección es $\approx 10^{-16}$, es decir, cero numérico. Para mostrar el efecto de la corrección conviene reportar:

- la correlación **antes** de la corrección, $|r(\tilde{E}, \tilde{T})|$, y
- el coeficiente de determinación $R^2 = 1 - \|E_{corr}\|^2 / \|\tilde{E} - \bar{\tilde{E}}\|^2$, que es la fracción de la variación del canal eléctrico atribuida a la topografía.

3. Filtro de ruido impulsivo (sal y pimienta selectivo)

Para una imagen I y una ventana $k_1 \times k_2$:

1. **Filtro de mediana** (MATLAB `medfilt2`, relleno de ceros en el borde):

$$M(i, j) = \text{med}\{I(u, v) : (u, v) \in W_{k_1 \times k_2}(i, j)\}.$$

2. **Residuo absoluto**: $R(i, j) = |I(i, j) - M(i, j)|$.

3. **Estimación robusta del nivel de ruido**:

$$\hat{\sigma} = \frac{\text{med}(R)}{0.6745}.$$

Justificación: si el residuo de un píxel normal sigue una distribución $\mathcal{N}(0, \sigma^2)$, entonces $|R|$ tiene mediana $\Phi^{-1}(0.75) \sigma = 0.6745 \sigma$, donde Φ es la función de distribución normal estándar. Dividir entre 0.6745 da un estimador consistente de σ . Como la mediana ignora hasta el 50 % de valores anómalos, los propios *outliers* no inflan la estimación.

4. **Reemplazo selectivo:** solo se modifican los píxeles anómalos.

$$I_{out}(i, j) = \begin{cases} M(i, j), & R(i, j) > n \hat{\sigma} \\ I(i, j), & \text{en otro caso.} \end{cases}$$

Instancias usadas:

Instancia	Entrada	Ventana	n	Objetivo
SyP 1	E_{corr}	5×5	3	píxeles aislados extremos
SyP 2	E_{fondo}	5×1	2	líneas horizontales impulsivas
SyP en E_B	$E_{corr,B}$	5×5	3	ídem SyP 1 en escala física

La ventana 5×1 es vertical: 5 filas por 1 columna. Cada píxel se compara solo con los dos píxeles de arriba y los dos de abajo en la misma columna. Si una línea de barrido completa (o un tramo) está desplazada respecto a sus vecinas, su residuo vertical es grande y se reemplaza. Una ventana horizontal no detectaría esto, porque todos los píxeles de la línea defectuosa tendrían vecinos igual de defectuosos.

4. Corrección de fondo por fila

Se aplica a E_1 (salida de SyP 1) y elimina el desplazamiento de nivel de cada línea de barrido. Para cada fila i , con vector $I_i = E_1(i, \cdot)$:

1. **Variabilidad relativa:**

$$\rho_i = \frac{\text{MAD}(I_i)}{P_{95}(I_i) - P_5(I_i)}.$$

2. **Percentil adaptativo:**

$$p_i = \min(45, \max(25, 40 - 20 \rho_i)) \, \%.$$

3. **Nivel de fondo:** mediana de los píxeles por debajo del percentil p_i :

$$b_i = \text{med}\{I_i(j) : I_i(j) \leq P_{p_i}(I_i)\}.$$

4. **Sustracción:** $E_{fondo}(i, j) = I_i(j) - b_i$.

Fundamento: los CNTs aparecen como valores altos del gradiente de capacitancia. Por eso los píxeles más bajos de cada fila son mayoritariamente matriz polimérica, y su mediana estima el nivel base de esa línea. Al restarla se alinean todas las filas al mismo fondo.

Comportamiento real del percentil. Como $\rho_i \geq 0$, siempre se cumple $40 - 20\rho_i \leq 40$: la cota superior de 45 % nunca se alcanza. Para llegar a la cota inferior de 25 % haría falta $\rho_i \geq 0.75$, lo que no ocurre en distribuciones realistas. Valores de referencia:

Tipo de fila	ρ	p
ruido gaussiano puro	≈ 0.21	$\approx 36 \%$
20 % de píxeles CNT	≈ 0.07	$\approx 38.5 \%$
50 % de píxeles CNT (bimodal)	≈ 0.40	$\approx 32 \%$
distribución uniforme	≈ 0.29	$\approx 34 \%$

En la práctica, el fondo se estima con el 32–39 % de píxeles más bajos de cada fila. El percentil baja cuando la fila tiene una fracción grande de CNTs (distribución bimodal), justo el caso en que un percentil alto contaminaría el fondo con CNTs.

5. Normalización a $[0, 1]$

Tras SyP 2 se obtiene E_{clean} , que se escala de forma robusta entre sus percentiles 1 y 99:

$$E_{seg}(i, j) = \min\left(1, \max\left(0, \frac{E_{clean}(i, j) - P_1}{P_{99} - P_1}\right)\right).$$

El 1 % de valores extremos de cada lado se satura. Así, todas las imágenes quedan con el mismo rango dinámico y unos pocos píxeles no dominan la escala de los umbrales.

Orden completo de la cadena de preprocesamiento:

$$E_{raw} \xrightarrow{\text{norm. robusta}} \tilde{E} \xrightarrow{\text{crosstalk}} E_{corr} \xrightarrow{\text{SyP } 5 \times 5} E_1 \xrightarrow{\text{fondo}} E_{fondo} \xrightarrow{\text{SyP } 5 \times 1} E_{clean} \xrightarrow{P_1 - P_{99}} E_{seg}$$

6. Binarización multiescala

6.1 Binarización local M_L y regional M_R

Ambas usan umbralización adaptativa con estadístico gaussiano (`adaptthresh` + `imbinarize`), con parámetro `NeighborhoodSize` = n :

1. **Fondo local:** promedio de E_{seg} ponderado con un núcleo gaussiano. En el código fuente de `adaptthresh`, la opción `'gaussian'` ejecuta

```
T = scaleFactor*imgaussfilt(I, nhoodSize);
```

El segundo argumento de `imgaussfilt` es la **desviación estándar** del núcleo, no el tamaño de la ventana. Por lo tanto, n **actúa como** σ :

$$\mu_G(i, j) = \sum_{(u, v)} G_n(u - i, v - j) E_{\text{seg}}(u, v), \quad G_n(\Delta u, \Delta v) = \frac{1}{Z} \exp\left(-\frac{\Delta u^2 + \Delta v^2}{2n^2}\right),$$

donde Z normaliza los pesos a suma 1. El núcleo se trunca en un soporte de $2\lceil 2n \rceil + 1$ píxeles por lado (tamaño por defecto de `imgaussfilt`) y la imagen se extiende en los bordes replicando el último valor ('`replicate`').

	$n (= \sigma)$	σ físico	Soporte del núcleo	Soporte físico
M_L	21 px	$\approx 1.23 \mu\text{m}$	85×85 px	$\approx 5.0 \mu\text{m}$
M_R	51 px	$\approx 2.99 \mu\text{m}$	205×205 px	$\approx 12.0 \mu\text{m}$

En 2D, la fracción del peso dentro de un radio $k\sigma$ es $1 - e^{-k^2/2}$: el 39 % del peso está a menos de σ del píxel y el 86 % a menos de 2σ . El vecindario efectivo de M_L tiene entonces un radio del orden de 20-40 px (≈ 1.2 - $2.5 \mu\text{m}$), y el de M_R de 50-100 px (≈ 3 - $6 \mu\text{m}$). **No son ventanas de 21×21 y 51×51 px**, como se describe actualmente en la tesis.

2. Umbral escalado por la sensibilidad (polaridad `bright`):

$$\tau(i, j) = \min(1, \gamma(s) \mu_G(i, j)), \quad \gamma(s) = 0.6 + (1 - s).$$

Con $s = 0.55$: $\gamma = 1.05$ (**confirmado en MATLAB**: la prueba siguiente devuelve 0.5250):

```
T =
adaptthresh(0.5*ones(64),0.55,'Statistic','gaussian','ForegroundPolarity','bright');
T(32,32) % 0.525 confirma  $\gamma = 1.05$ 
```

3. Decisión:

$$M(i, j) = \begin{cases} 1, & E_{\text{seg}}(i, j) > \tau(i, j) \\ 0, & \text{en otro caso.} \end{cases}$$

Es decir, un píxel es CNT si su intensidad supera en un 5 % la media gaussiana de su vecindad. Mayor sensibilidad s significa menor γ , umbral más bajo y más píxeles clasificados como CNT.

Qué significa el factor $\gamma = 1.05$

La idea. La binarización adaptativa no compara cada píxel con un umbral fijo, sino con **su propio vecindario**. Primero calcula $\mu_G(i, j)$, el brillo “típico” alrededor del píxel. Luego exige que el píxel sea más brillante que ese valor típico multiplicado por un factor γ :

$$E_{\text{seg}}(i, j) > \gamma \mu_G(i, j) \quad \Longleftrightarrow \quad \frac{E_{\text{seg}}(i, j)}{\mu_G(i, j)} > \gamma.$$

El criterio es un **contraste relativo**: el cociente entre el píxel y su vecindario.

γ	Exigencia	Efecto
> 1	el píxel debe ser más brillante que su vecindario	solo se marcan picos locales
$= 1$	basta con superar el promedio local	aproximadamente la mitad de cada vecindario queda marcada
< 1	basta con no ser mucho más oscuro que el vecindario	casi todo queda marcado, incluido el fondo

De dónde sale 1.05. MATLAB no recibe γ directamente, sino la *sensibilidad* $s \in [0, 1]$, y la convierte con $\gamma(s) = 0.6 + (1 - s)$:

s	γ	Interpretación
0.0	1.60	el píxel debe superar en 60 % a su vecindario
0.3	1.30	+30 %
0.5 (valor por defecto de MATLAB)	1.10	+10 %
0.55 (tesis)	1.05	+5 %
0.6	1.00	igual al promedio
0.8	0.80	puede ser hasta 20 % más oscuro
1.0	0.60	puede ser hasta 40 % más oscuro

Así se explica el nombre: a mayor sensibilidad, menos contraste se exige y se detectan más píxeles (incluidos CNTs profundos de bajo contraste, pero también más ruido de fondo).

Ejemplo numérico con $s = 0.55$, en una zona de fondo con $\mu_G = 0.20$, de modo que el umbral es $1.05 \times 0.20 = 0.21$:

Píxel	E_{seg}	¿Supera 0.21?	Resultado
fondo polimérico	0.19	no	fondo ✓
fondo con ruido	0.205	no	fondo ✓
CNT profundo (contraste débil)	0.24	sí (+20 %)	CNT ✓
CNT superficial	0.60	sí	CNT ✓

Por qué el documento actual da otro resultado. La tesis escribe el criterio como $E_{seg} > \mu_G(1 - \alpha_s)$. Con $\alpha_s = 0.55$ eso es $E_{seg} > 0.45 \mu_G$, es decir $\gamma = 0.45$. En el ejemplo, el umbral sería 0.09 y **los cuatro píxeles, incluido el fondo, saldrían como CNT**: un píxel solo sería fondo si fuera menos de la mitad de brillante que su vecindario. No es lo que hace el código.

Evidencia en tus propios resultados. En la validación de parámetros (Cap. 4) la cobertura pasa de 11.5 % con $s = 0.3$ a 45.2 % con $s = 0.8$:

- Con la fórmula del documento, $s = 0.3$ daría $\gamma = 0.7$: casi todo el fondo pasaría el umbral local y la cobertura no podría ser tan baja.

- Con $\gamma(s) = 0.6 + (1 - s)$, $s = 0.3$ da $\gamma = 1.3$ (exigir +30 %, cobertura baja) y $s = 0.8$ da $\gamma = 0.8$ (cobertura alta). Esto coincide con lo observado.

Consecuencias: - Corrección para la tesis: reemplazar la ecuación por $M_L(i, j) = 1$ si $E_{seg}(i, j) > (1.6 - s) \mu_G(i, j)$, y explicar que con $s = 0.55$ el criterio equivale a un contraste local mínimo del 5 %. - **Limitación a mencionar:** el criterio es relativo. En zonas oscuras (μ_G pequeño), un 5 % es una diferencia absoluta mínima y el ruido la supera con facilidad. Esa es la “fragmentación granular en el fondo” que muestra M_L , y la razón para intersecarla con M_G , que usa un umbral absoluto, y con M_R , que usa un vecindario más amplio. - **Confirmado:** sobre una imagen constante de valor 0.5, `adaptthresh` con $s = 0.55$ devuelve un umbral de $0.525 = 1.05 \times 0.5$. El código fuente lo fija en `sensitivityToScaleFactor: scaleFactor = 0.6 + (1-sensitivity)` para polaridad `bright`, y el umbral final se recorta a $[0, 1]$.

Máscara	Escala (σ)	Papel
M_L	$\sigma = 21$ px ($\approx 1.2 \mu\text{m}$)	detalle fino; sigue variaciones sutiles, pero genera falsos positivos granulares en el fondo
M_R	$\sigma = 51$ px ($\approx 3 \mu\text{m}$)	contexto regional; descarta estructuras que solo son brillantes respecto a una vecindad pequeña

6.2 Binarización global M_G : Otsu multinivel

`multithresh` divide el histograma de E_{seg} en $K + 1$ clases con K umbrales $t_1 < \dots < t_K$, escogidos para maximizar la varianza entre clases:

$$\{t_k\} = \arg \max \sigma_B^2 = \sum_{c=0}^K \omega_c (\mu_c - \mu_{tot})^2,$$

donde ω_c es la fracción de píxeles en la clase c , μ_c su intensidad media y μ_{tot} la media global. Con $K = 6$ se obtienen **7 clases**. La clase más oscura, $E_{seg} < t_1$, corresponde al fondo polimérico y se descarta:

$$M_G(i, j) = 1 [E_{seg}(i, j) \geq t_1].$$

Las 6 clases restantes agrupan distintos niveles de señal de CNT (superficiales y profundos). El umbral es único para toda la imagen; se trata de un método multinivel, no multiescala. El código además elimina de M_G las componentes menores a $A_{\min}$, lo que no altera el resultado final (ver 6.3).

6.3 Integración

Un píxel pertenece a la red solo si las tres escalas coinciden, y luego se eliminan las componentes pequeñas:

$$M_e = \mathcal{A}_{A_{\min}}(M_L \wedge M_G \wedge M_R),$$

donde $\mathcal{A}_A(M)$ elimina de M toda componente conexa con menos de A píxeles (`bwareaopen`).

Cada componente de la intersección está contenida en una componente de M_G . Por tanto, una componente pequeña de M_G solo puede producir componentes pequeñas en la intersección, que $\mathcal{A}$ ya elimina; por eso el filtrado previo de M_G es redundante.

6.4 Cobertura y respaldo

$$c = \frac{1}{N^2} \sum_{i,j} M_e(i,j).$$

Si $c < 0.15$, se usa solo la escala local: $M_e \leftarrow \mathcal{A}_{50}(M_L)$, con los mismos parámetros. La cobertura reportada es la de la máscara final.

7. Representaciones de trabajo

7.1 Máscara estricta M_e

La salida de la sección 6.

7.2 Máscara morfológica M_{mor}

Cierre morfológico con un disco B_r de radio $r = 3$ px:

$$M_{mor} = M_e \bullet B_r = (M_e \oplus B_r) \ominus B_r.$$

La dilatación $\oplus$ une regiones separadas por huecos de hasta $\approx 2r$ px; la erosión $\ominus$ devuelve los bordes a su posición. El resultado rellena discontinuidades de escala $\lesssim 2r\Delta \approx 350$ nm sin engrosar las estructuras. `strel('disk',3)` aproxima el disco mediante descomposición en elementos lineales (opción por defecto).

7.3 Esqueleto S

$$S = \text{spur}^{(5)}(\text{skel}(M_{mor})).$$

`bwskel` adelgaza cada componente hasta una línea de 1 px que conserva su topología (eje medial). `bwmorph(·, 'spur', 5)` elimina 5 veces seguidas los píxeles extremos (píxeles con un solo vecino), lo que borra ramas espurias de hasta ≈ 5 px. Esas ramas aparecen al esqueletizar bordes irregulares.

7.4 Imagen eléctrica reconstruida E_B

Es la señal en unidades físicas para los descriptores de intensidad y de perfil.

1. **Deshacer la normalización conservando la corrección:** como $E_{corr} = (E_{raw} - \text{med})/\text{MAD} - \hat{E}_T$, multiplicando por la MAD y sumando la mediana:

$$E_{corr,B} = E_{raw} - \text{MAD}(E_{raw}) \hat{E}_T \quad [\text{m}].$$

2. **SyP** 5×5 , $n = 3 \rightarrow E_{syp}$.

3. **Perfil vertical**: $p(i) = \text{med}_j E_{syp}(i, j)$.

4. **Tendencia RLOESS**: $\tilde{p} = \text{rloess}_w(p)$, con $w = 50$ filas. En cada ventana de 50 filas se ajusta una parábola por mínimos cuadrados ponderados: los pesos tricúbicos $W(d) = (1 - |d|^3)^3$ privilegian las filas cercanas al centro. Luego el ajuste se repite con pesos de robustez *bisquare* calculados de los residuos, de modo que los saltos abruptos entre filas no arrastren la tendencia.

5. **Rayas**: $\delta(i) = p(i) - \tilde{p}(i)$, la componente de alta frecuencia fila a fila.

6. **Sustracción por fila**:

$$E_B(i, j) = E_{syp}(i, j) - \delta(i).$$

E_B no pasa por la corrección de fondo (sección 4) ni por la normalización. Así conserva los valores absolutos del gradiente y la tendencia vertical de baja frecuencia, que la sección 4 eliminaría.

Consecuencia: como restar una constante a una fila desplaza su mediana en esa misma constante,

$$\text{med}_j E_B(i, j) = p(i) - \delta(i) = \tilde{p}(i).$$

El perfil vertical de E_B es exactamente la tendencia RLOESS (ver sección 13).

8. Descriptores de distribución espacial (sobre M_{mor})

8.1 Muestreo con líneas de barrido

Con semilla fija (`rng(42)`), se eligen 100 filas $r_1, \dots, r_{100}$ uniformemente y con reemplazo. Son las mismas filas para todas las imágenes. En cada fila, la secuencia binaria $M_{mor}(r, \cdot)$ se descompone en tramos consecutivos de unos (CNT) y ceros (polímero). Para el tramo m de CNT con inicio a_m y final e_m :

$$\ell_m = (e_m - a_m + 1) \Delta \quad (\text{longitud de tramo CNT}),$$

$$d_m = (a_{m+1} - e_m - 1) \Delta \quad (\text{espaciado entre tramos CNT consecutivos}).$$

Los huecos entre el borde de la imagen y el primer o último CNT **no** cuentan como espaciado, porque no están delimitados por dos CNTs. Los tramos CNT que tocan el borde **sí** se cuentan, aunque estén truncados. Se juntan todos los ℓ_m y d_m de las 100 líneas.

8.2 Ajuste lognormal

Para una muestra $\{x_k\}_{k=1}^n$ (espaciados o longitudes), el ajuste de máxima verosimilitud (`fitdist`) da:

$$\hat{\mu} = \frac{1}{n} \sum_k \ln x_k, \quad \hat{\sigma}^2 = \frac{1}{n-1} \sum_k (\ln x_k - \hat{\mu})^2,$$

con densidad y función de distribución

$$f(x) = \frac{1}{x \hat{\sigma} \sqrt{2\pi}} \exp\left(-\frac{(\ln x - \hat{\mu})^2}{2\hat{\sigma}^2}\right), \quad F(x) = \Phi\left(\frac{\ln x - \hat{\mu}}{\hat{\sigma}}\right).$$

(MATLAB usa la versión insesgada $n-1$ para $\hat{\sigma}$.) Si hay 10 medidas o menos, el descriptor se reporta como NaN.

8.3 CNTD: uniformidad de espaciado

La moda de la lognormal se obtiene de $\frac{d}{dx} f(x) = 0$:

$$\eta = e^{\hat{\mu} - \hat{\sigma}^2}.$$

El descriptor es la probabilidad de que un espaciado caiga a $\pm 20\%$ de la moda:

$$\text{CNTD} = \int_{0.8\eta}^{1.2\eta} f(s) ds = F(1.2\eta) - F(0.8\eta).$$

Sustituyendo η en F , con $z_c = (\ln(c\eta) - \hat{\mu})/\hat{\sigma} = \ln(c)/\hat{\sigma} - \hat{\sigma}$:

$$\text{CNTD} = \Phi\left(\frac{\ln 1.2}{\hat{\sigma}} - \hat{\sigma}\right) - \Phi\left(\frac{\ln 0.8}{\hat{\sigma}} - \hat{\sigma}\right).$$

CNTD solo depende de $\hat{\sigma}$, la dispersión logarítmica de los espaciados, y no de su escala $\hat{\mu}$. Una $\hat{\sigma}$ pequeña indica una distribución concentrada y un CNTD alto, es decir, espaciado uniforme.

8.4 CNTA: aglomeración

Probabilidad de que un tramo de CNT supere $\alpha = 2000$ nm:

$$\text{CNTA} = \int_{\alpha}^{\infty} g(\ell) d\ell = 1 - G(\alpha),$$

donde G es la función de distribución lognormal ajustada a las longitudes. El resultado se recorta a $[0, 1]$.

8.5 CNTS

$$\text{CNTS} = \frac{\text{CNTA}}{\text{CNTD}} \quad (\text{NaN si alguno es NaN o CNTD} = 0).$$

9. Descriptores de intensidad (sobre E_B restringida a M_e)

Sea $\Omega_e = \{(i, j) : M_e(i, j) = 1\}$ con $|\Omega_e| = n_e$ píxeles, y la conversión $\kappa = 10^{12}$ pm/m.

$$\bar{E} = \frac{\kappa}{n_e} \sum_{\Omega_e} E_B, \quad s_E = \kappa \sqrt{\frac{1}{n_e - 1} \sum_{\Omega_e} (E_B - \bar{E}/\kappa)^2}, \quad E_{90} = \kappa P_{90}(E_B|_{\Omega_e}) \quad [\text{pm}].$$

Gradiente medio: el gradiente se calcula sobre toda E_B con diferencias centrales (sección 2.2), y luego se promedia sobre la red:

$$|\nabla E_B|(i, j) = \sqrt{\left(\frac{\partial E_B}{\partial x}\right)^2 + \left(\frac{\partial E_B}{\partial y}\right)^2} \quad [\text{m/px}],$$
$$|\overline{\nabla E}| = \frac{\kappa}{\Delta} \cdot \frac{1}{n_e} \sum_{\Omega_e} |\nabla E_B| \quad [\text{pm/nm}].$$

Dividir entre Δ convierte la variación por píxel en una derivada espacial física.

10. Descriptores de forma (sobre M_{mor})

Sean $C_1, \dots, C_{N_c}$ las componentes conexas de M_{mor} .

10.1 Elipse equivalente

Para cada componente C_k , con centroide $(\bar{x}, \bar{y})$, `regionprops` calcula los segundos momentos centrales normalizados. El término $1/12$ es el momento de un píxel unitario:

$$u_{xx} = \frac{1}{|C_k|} \sum (x - \bar{x})^2 + \frac{1}{12}, \quad u_{yy} = \frac{1}{|C_k|} \sum (y - \bar{y})^2 + \frac{1}{12}, \quad u_{xy} = \frac{1}{|C_k|} \sum (x - \bar{x})(y - \bar{y}).$$

Los valores propios de la matriz $\begin{pmatrix} u_{xx} & u_{xy} \\ u_{xy} & u_{yy} \end{pmatrix}$ son

$$\lambda_{1,2} = \frac{u_{xx} + u_{yy}}{2} \pm \frac{1}{2} \sqrt{(u_{xx} - u_{yy})^2 + 4u_{xy}^2},$$

y los ejes de la elipse con los mismos momentos son $a_k = 4\sqrt{\lambda_1}$ (mayor) y $b_k = 4\sqrt{\lambda_2}$ (menor).

10.2 Elongación media

$$\text{Elong} = \frac{1}{N_c} \sum_{k=1}^{N_c} \frac{a_k}{b_k} = \frac{1}{N_c} \sum_k \sqrt{\frac{\lambda_{1,k}}{\lambda_{2,k}}}.$$

Vale 1 para una componente isótropa y crece con la anisotropía. Si $b_k = 0$ (componente perfectamente lineal), el código usa $b_k = 1$.

10.3 Área

$$\bar{A} = \frac{1}{N_c} \sum_k |C_k| \Delta^2 \cdot 10^{-6}, \quad s_A = \sqrt{\frac{1}{N_c - 1} \sum_k (|C_k| \Delta^2 \cdot 10^{-6} - \bar{A})^2} \quad [\mu\text{m}^2].$$

10.4 Tortuosidad media (sobre el esqueleto S)

Para cada componente conexa S_j del esqueleto:

1. Se descarta si tiene menos de 8 px o menos de 2 extremos (por ejemplo, un lazo cerrado).
2. **Distancia geodésica** $D(p, q)$: el camino más corto dentro de S_j , con pasos ortogonales de peso 1 y diagonales de peso $\sqrt{2}$ (`bwdistgeodesic`, `quasi-euclidean`).
3. **Diámetro por doble barrido**: desde un extremo cualquiera e_0 se busca el extremo más lejano $A = \arg \max_e D(e_0, e)$, y desde A el más lejano $B = \arg \max_e D(A, e)$. En un árbol (esqueleto sin ciclos), $D(A, B)$ es exactamente el camino más largo entre extremos. Con ciclos es una aproximación.
4. Arco y cuerda:

$$L_j^{arco} = D(A, B), \quad L_j^{cuerda} = \|A - B\|_2.$$

5. Se descarta si $L_j^{arco} < 15$ px.

$$\tau = \frac{1}{M} \sum_{j=1}^M \frac{L_j^{arco}}{L_j^{cuerda}} \geq 1,$$

donde M es el número de componentes **retenidas**. $\tau = 1$ indica estructuras rectas; valores mayores, estructuras más sinuosas. Como es un cociente, no depende de Δ .

11. Descriptores de orientación (tensor de estructura sobre M_{mor})

1. **Suavizado de la máscara**: $G = M_{mor} * g_{\sigma_d}$, con $\sigma_d = 2$ px. Esto convierte la máscara binaria en un campo continuo cuyo gradiente apunta perpendicular a los bordes de las estructuras.
2. **Gradiente**: $(G_x, G_y) = \nabla G$, por diferencias centrales.
3. **Tensor local** (promedio gaussiano de escala $\sigma_i = 8$ px):

$$J_{xx} = g_{\sigma_i} * G_x^2, \quad J_{yy} = g_{\sigma_i} * G_y^2, \quad J_{xy} = g_{\sigma_i} * (G_x G_y).$$

4. **Acumulación sobre la red** $\Omega_{mor} = \{M_{mor} = 1\}$:

$$\mathbf{J} = \begin{pmatrix} S_{xx} & S_{xy} \\ S_{xy} & S_{yy} \end{pmatrix}, \quad S_{ab} = \sum_{\Omega_{mor}} J_{ab}.$$

5. **Valores propios:**

$$\lambda_{1,2} = \frac{S_{xx} + S_{yy}}{2} \pm \frac{1}{2} \sqrt{(S_{xx} - S_{yy})^2 + 4S_{xy}^2}.$$

6. **Dirección dominante del gradiente**, que es el vector propio de λ_1 :

$$\theta_{\nabla} = \frac{1}{2} \text{atan2}(2S_{xy}, S_{xx} - S_{yy}).$$

Las estructuras son perpendiculares al gradiente, así que la **orientación dominante** es

$$\theta = (\theta_{\nabla} + 90^\circ) \bmod 180^\circ \in [0^\circ, 180^\circ).$$

Convención: θ se mide desde el eje x (horizontal, dirección de barrido tras el `rot90`). Como el eje y de la imagen apunta hacia abajo, los ángulos crecen en sentido horario en la imagen mostrada.

7. **Coherencia:**

$$C = \frac{\lambda_1 - \lambda_2}{\lambda_1 + \lambda_2} \in [0, 1].$$

$C \rightarrow 1$ indica que toda la red comparte una misma dirección; $C \rightarrow 0$, que no hay dirección preferente, en cuyo caso θ no es significativo. Si $|\Omega_{mor}| \leq 10$, ambos se reportan como NaN.

12. Descriptores de conectividad y topología

Cobertura total (sobre M_e):

$$c = \frac{|\Omega_e|}{N^2}.$$

Índice de percolación (sobre M_{mor}): fracción del material en el clúster mayor.

$$P = \frac{\max_k |C_k|}{\sum_k |C_k|} \in (0, 1].$$

Número de fragmentos: N_c , el número de componentes conexas de M_{mor} .

Longitud de red (sobre S): cada enlace entre píxeles vecinos del esqueleto suma su longitud euclidiana:

$$n_{\perp} = |\{\text{pares de píxeles de } S \text{ adyacentes en horizontal o vertical}\}|,$$

$$n_{\times} = |\{\text{pares adyacentes en diagonal sin un camino ortogonal que los conecte}\}|,$$

$$L_{red} = (n_{\perp} + \sqrt{2} n_{\times}) \Delta \cdot 10^{-3} \quad [\mu\text{m}].$$

Se excluyen las diagonales que ya tienen un camino ortogonal (forma de “L”) para no contar dos veces el mismo tramo.

13. Descriptores de perfil de gradiente (sobre E_B)

Perfil vertical: $q(i) = \text{med}_j E_B(i, j)$, con $i = 1, \dots, N$. Por la sección 7.4, $q = \tilde{p}$, la **tendencia RLOESS**. Sobre él se ajusta una recta por mínimos cuadrados:

$$\hat{q}(i) = m i + b, \quad m = \frac{\sum_i (i - \bar{i})(q_i - \bar{q})}{\sum_i (i - \bar{i})^2}, \quad b = \bar{q} - m \bar{i}.$$

Descriptor	Fórmula	Unidad
Pendiente	$\kappa m / \Delta$	pm/nm
RMS del residuo	$\kappa \sqrt{\frac{1}{N} \sum_i (q_i - \hat{q}_i)^2}$	pm
Rango	$\kappa (\max_i q_i - \min_i q_i)$	pm

Interpretación: como las rayas $\delta(i)$ ya se restaron, estos descriptores caracterizan la variación vertical de **baja frecuencia** de la señal:

- la pendiente es la tendencia lineal global;
- el RMS del residuo mide cuánto se curva la tendencia RLOESS respecto a la recta (no linealidad), no el ruido entre filas;
- el rango es la excursión total de la tendencia.

14. Salida

Una fila por imagen en `descriptores.csv`, con identificación (archivo, voltaje, frecuencia, réplica, posición) y los 20 descriptores:

Grupo	Descriptores	Representación
Distribución espacial	CNTD, CNTA, CNTS	M_{mor} (líneas de barrido)
Intensidad	media, desv., P90, gradiente medio	E_B en M_e
Forma	elongación, área media, área desv., tortuosidad	M_{mor}, S
Orientación	orientación dominante, coherencia	M_{mor}
Conectividad	cobertura, percolación, longitud de red, fragmentos	M_e, M_{mor}, S
Perfil	pendiente, RMS residuo, rango	E_B