Capítulo 3

Metodología

Este capítulo describe los procedimientos aplicados sobre el conjunto de datos de microscopía de fuerza electrostática de segundo armónico (EFM-2ω) empleado en este trabajo. La descripción se organiza en torno a los objetivos específicos del proyecto (Sección 1.1), registrando la metodología aplicada en aquellos en que sea necesaria, con el fin de asegurar la claridad y reproducibilidad del trabajo. Estos objetivos son: el procesamiento digital de los datos de microscopía para reducir el ruido y aumentar el contraste de la red de nanotubos respecto a la matriz polimérica, la extracción de descriptores morfológicos físicamente interpretables a partir de las imágenes procesadas y los procedimientos de ML enfocados en la relación SE-descriptores.

3.1. Procesamiento Digital de Imágenes

Las mediciones de microscopía se obtienen en formato .ibw (Igor Binary Wave), el formato de salida del microscopio MFP-3D (Asylum Research) con el que fueron adquiridas. Estos archivos contienen múltiples canales de información adquiridos durante el escaneo EFM-2ω, técnica en la que se aplica a la punta un voltaje alterno de frecuencia angular ω y se registra la respuesta del cantiléver a la frecuencia 2ω (Capítulo 2); cada canal es una matriz de $N \times N$ mediciones, con $N = 1024$, que cubre un área de barrido de 60×60 μm, con una separación $\Delta = 60\ \mu\text{m}/1024 \approx 58{,}6$ nm entre mediciones contiguas. En este trabajo se emplean dos canales: el canal eléctrico I_{raw}, que corresponde a la amplitud del segundo armónico de la vibración del cantiléver y es proporcional al gradiente de capacitancia $\partial C/\partial z$, donde C es la capacitancia entre la punta y la muestra y z la distancia vertical entre ambas [5], y el canal topográfico T_{raw}, que recoge las mediciones de variación de altura en la superficie de la muestra, información necesaria para corregir su influencia sobre el canal eléctrico como primer paso del procesamiento, descrito a continuación (Sección 3.1.1).

El conjunto de datos está formado por 81 mediciones: nueve condiciones de fabricación, resultado de combinar tres voltajes (5, 10 y 15 V) y tres frecuencias (10 Hz, 1 kHz y 100 kHz)

[4], con tres réplicas por condición y tres posiciones de medición por réplica. Cada medición se identifica con un código de la forma `Vf-n`: `V` indica el voltaje (0, 1 y 2 para 5, 10 y 15 V), `f` la frecuencia (a, b y c para 10 Hz, 1 kHz y 100 kHz) y $n \in \{1, \ldots, 9\}$ la medición, de modo que las mediciones 1–3, 4–6 y 7–9 corresponden a la primera, segunda y tercera réplica. El conjunto de las nueve mediciones de una condición se denomina *set*; por ejemplo, el set 2b corresponde a 15 V y 1 kHz.

Ambos canales se leen en MATLAB y se rotan 90° (`rot90`), de modo que cada fila de la matriz corresponde a una línea de barrido. Para su procesamiento, cada matriz se trata como una imagen digital en escala de grises, es decir, como una función bidimensional discreta cuyo valor en cada posición es la medición correspondiente [6]; esto permite aplicarle las operaciones de procesamiento digital de imágenes descritas en este capítulo. Bajo esta interpretación, cada elemento de la matriz se denomina píxel; las filas se indexan con i (eje y), las columnas con j (eje x, a lo largo de la línea de barrido), y los parámetros espaciales se expresan en píxeles (1 px $= \Delta \approx 58{,}6$ nm). El valor de un canal X en el píxel de la fila i y la columna j, con $i, j \in \{1, \ldots, N\}$, se denota $X(i, j)$. El canal topográfico se guarda nivelado por el software de adquisición, que resta a cada línea de barrido su ajuste lineal (nivelado de primer orden), mientras que el canal eléctrico se guarda sin nivelar. La sensibilidad de la detección del segundo armónico no se calibró durante la adquisición, por lo que el canal eléctrico se expresa en unidades nominales: es proporcional al valor real con un factor desconocido, constante dentro de cada medición pero no necesariamente entre sesiones de medición.

La visualización de las matrices es un proceso paralelo al procesamiento y no interviene en ningún cálculo. Para inspeccionar cada etapa y construir las figuras de este documento, cada matriz se representa como una imagen en color con la función `imagesc` de MATLAB y ejes de igual escala (`axis image`), de modo que cada píxel se dibuja como un cuadrado de Δ de lado. A cada píxel se le asigna un color del mapa de color *viridis* (256 colores) según su valor. La asignación es lineal entre dos límites: para las matrices de valores continuos, sus percentiles 1 y 99, de modo que los valores fuera de ese rango toman el color del extremo correspondiente; para las máscaras binarias, los valores 0 y 1. Salvo que se indique lo contrario en la figura, los límites se calculan por separado para cada matriz, por lo que los colores de dos figuras distintas no son comparables entre sí.

A lo largo del procesamiento se emplean dos estadísticos de orden sobre un conjunto de valores $\mathcal{D}$, por ejemplo todos los píxeles de una medición o todos los de una fila. La mediana, $\mathrm{med}(\mathcal{D})$, es el valor central del conjunto ordenado (el promedio de los dos centrales si el número de valores es par). El percentil q, $P_q(\mathcal{D})$, es el valor por debajo del cual se encuentra el $q\,\%$ de los valores; se calcula con la función `prctile` de MATLAB, que interpola linealmente entre los valores ordenados.

El procesamiento aplica al canal eléctrico la siguiente secuencia de operaciones, descritas en las secciones siguientes en el mismo orden en que se aplican (SyP: filtro de ruido impulsivo tipo sal y pimienta; cada matriz intermedia se define en la sección correspondiente):

$$I_{raw} \xrightarrow{\text{crosstalk}} I_{corr} \xrightarrow{\text{SyP } 5\times5} I_{syp} \xrightarrow{\text{fondo}} I_{fondo} \xrightarrow{\text{líneas } 5\times1} I_{clean} \xrightarrow{P_1-P_{99}} I_{seg} \xrightarrow{\text{binarización}} M_e \tag{3.1}$$

A partir de la máscara M_e y de una reconstrucción del canal eléctrico en su escala original, I_B, se construyen las representaciones de trabajo sobre las que se calculan los descriptores (Sección 3.1.7).

3.1.1. Corrección de Crosstalk Topográfico

Como primera etapa se elimina el crosstalk topográfico [8], una de las componentes de ruido visualmente más presentes del dataset. Esta corrección se aplica antes que cualquier otra operación que pueda alterar la relación entre el canal eléctrico y el topográfico.

Ambos canales se normalizan primero de forma robusta, restando su mediana y dividiendo por su desviación absoluta mediana (MAD):

$$\tilde{I}(i,j) = \frac{I_{raw}(i,j) - \mathrm{med}(I_{raw})}{\mathrm{MAD}(I_{raw})}, \qquad \tilde{T}(i,j) = \frac{T_{raw}(i,j) - \mathrm{med}(T_{raw})}{\mathrm{MAD}(T_{raw})}, \qquad \mathrm{MAD}(\mathcal{D}) = \mathrm{med}\left(|\mathcal{D} - \mathrm{med}(\mathcal{D})|\right. \tag{3.2}$$

donde $\tilde{I}$ y $\tilde{T}$ son los canales eléctrico y topográfico normalizados (la tilde indica normalización), adimensionales y comparables entre sí; $|\mathcal{D} - \mathrm{med}(\mathcal{D})|$ es el conjunto de las desviaciones absolutas de cada valor respecto a la mediana, y la mediana y la MAD de cada canal se calculan sobre todos los píxeles de la medición. Se emplean la mediana y la MAD en lugar de la media y la desviación estándar porque no se ven afectadas por valores extremos derivados del ruido.

A partir de los canales normalizados se ajusta un modelo de regresión lineal múltiple de la forma:

$$\tilde{I}(i,j) = \beta_0 + \beta_1 \tilde{T}(i,j) + \beta_2 \frac{\partial \tilde{T}}{\partial x}(i,j) + \beta_3 \frac{\partial \tilde{T}}{\partial y}(i,j) + \varepsilon(i,j) \tag{3.3}$$

donde $\beta_0, \ldots, \beta_3$ son los coeficientes del modelo, $\varepsilon(i,j)$ es el residuo, y $\partial\tilde{T}/\partial x$ y $\partial\tilde{T}/\partial y$ son las variaciones direccionales de la topografía, calculadas por diferencias centrales (función `gradient` de MATLAB):

$$\frac{\partial \tilde{T}}{\partial x}(i,j) = \frac{\tilde{T}(i,j+1) - \tilde{T}(i,j-1)}{2}, \qquad \frac{\partial \tilde{T}}{\partial y}(i,j) = \frac{\tilde{T}(i+1,j) - \tilde{T}(i-1,j)}{2} \tag{3.4}$$

expresadas por píxel; en la primera y la última columna (o fila) se usa la diferencia de un solo lado, por ejemplo $\tilde{T}(i,2) - \tilde{T}(i,1)$.

El modelo se ajusta una sola vez por medición, sobre la matriz completa: cada uno de los N^2 píxeles aporta una ecuación de la forma (3.3), y los coeficientes se estiman por mínimos cuadrados, es decir, como los valores $\hat{\beta}_0, \ldots, \hat{\beta}_3$ que minimizan la suma de los residuos al cuadrado sobre todos los píxeles:

$$(\hat{\beta}_0, \ldots, \hat{\beta}_3) = \arg \min_{\beta_0,\ldots,\beta_3} \sum_{i=1}^{N} \sum_{j=1}^{N} \varepsilon(i,j)^2 \tag{3.5}$$

Este problema se resuelve con el operador $\backslash$ de MATLAB, mediante factorización QR. Cada medición tiene así un único conjunto de coeficientes. Con ellos se construye la componente del canal eléctrico explicada por la topografía:

$$\hat{I}_T(i,j) = \hat{\beta}_0 + \hat{\beta}_1 \tilde{T}(i,j) + \hat{\beta}_2 \frac{\partial \tilde{T}}{\partial x}(i,j) + \hat{\beta}_3 \frac{\partial \tilde{T}}{\partial y}(i,j) \tag{3.6}$$

donde el acento circunflejo indica que se trata de un valor estimado por el ajuste y el subíndice T, que es la parte atribuida a la topografía. $\hat{I}_T$ es un mapa con un valor distinto en cada píxel, que se resta píxel a píxel al canal eléctrico normalizado, eliminando las variaciones originadas en la topografía:

$$I_{corr}(i,j) = \tilde{I}(i,j) - \hat{I}_T(i,j) \tag{3.7}$$

Por construcción de los mínimos cuadrados, I_{corr} tiene media nula y correlación nula con $\tilde{T}$ y con sus derivadas, por lo que la correlación posterior a la corrección no mide su efectividad. Esta se evalúa visualmente sobre las mediciones con crosstalk más marcado (Capítulo 4).

El modelo es empírico: su objetivo es eliminar las huellas topográficas del canal eléctrico, y sus coeficientes no se interpretan físicamente. Como el canal topográfico solo está nivelado en primer orden, conserva la curvatura del barrido del escáner a lo largo de cada línea, que no corresponde al relieve de la muestra; en la segunda pasada de la medición EFM-2ω (Capítulo 2) la punta sigue la trayectoria registrada en la primera, por lo que esta curvatura no modifica la distancia punta–muestra ni genera crosstalk. Sin embargo, la curvatura entra al término de altura del modelo: en las mediciones con poco crosstalk vuelve inconsistente el coeficiente β_1 e introduce en el canal eléctrico una curvatura leve (mediana del 3 % de su variación). Esta curvatura

inyectada se cuantificó como la desviación estándar de la diferencia entre el canal corregido con la topografía original y el corregido con la topografía sin su perfil medio a lo largo de la línea, $\tilde{T}(i,j) - \frac{1}{N}\sum_{k=1}^{N}\tilde{T}(k,j)$, dividida por la desviación estándar de $\tilde{I}$. Para evaluar su efecto, los descriptores (Sección 3.2) se recalcularon con esta segunda versión de la corrección, y cada cambio se expresó en unidades de σ_{cond}, la desviación estándar del descriptor entre las nueve mediciones de una misma condición de fabricación, combinada sobre las nueve condiciones (σ^2_{cond} es el promedio de las nueve varianzas). Los cambios no presentan un sesgo sistemático; en los descriptores de intensidad son inferiores a $0{,}15\,\sigma_{cond}$, y en los morfológicos reflejan principalmente la sensibilidad de la binarización (Sección 3.1.6). Por ello se mantiene el modelo descrito.

3.1.2. Filtrado de Ruido Impulsivo

Para eliminar el ruido impulsivo se emplea un filtro de mediana bidimensional [6] aplicado de forma selectiva. El filtro se describe para una matriz de entrada genérica X y una ventana (kernel) de $a \times b$ píxeles (a filas por b columnas, ambos impares); en esta etapa, $a = b = 5$. El procedimiento tiene tres pasos.

Primero, la ventana se centra en cada píxel (i,j) y abarca el conjunto de píxeles

$$W_{a\times b}(i,j) = \left\{(u,v) : |u-i| \le \tfrac{a-1}{2},\ |v-j| \le \tfrac{b-1}{2}\right\} \tag{3.8}$$

donde (u,v) denota la fila y la columna de cada píxel de la ventana; es decir, el píxel central y sus vecinos hasta dos posiciones arriba, abajo, a la izquierda y a la derecha. El filtro de mediana asigna a cada píxel la mediana de los $a \cdot b$ valores de su ventana:

$$X_{med}(i,j) = \operatorname{med}\left\{X(u,v) : (u,v) \in W_{a\times b}(i,j)\right\} \tag{3.9}$$

En los bordes de la matriz, las posiciones de la ventana que quedan fuera se completan con ceros (comportamiento por defecto de la función `medfilt2` de MATLAB). La mediana es insensible a los propios outliers: un valor aislado extremo queda en un extremo del conjunto ordenado y no modifica el valor central, lo que la hace adecuada para esta tarea.

Segundo, sobre el residuo $R(i,j) = X(i,j) - X_{med}(i,j)$ obtenido entre la matriz previa X y la posterior al filtro X_{med} se estima la desviación típica del ruido, $\hat{\sigma}_{SyP}$, mediante un estimador robusto basado en la mediana absoluta, calculado una sola vez con todos los píxeles de la medición:

$$\hat{\sigma}_{SyP} = \frac{\operatorname{med}(|R|)}{0{,}6745} \tag{3.10}$$

El factor $0{,}6745$ es el percentil 75 de la distribución normal estándar, $\Phi^{-1}(0{,}75)$, donde Φ es su función de distribución acumulada: si el residuo de los píxeles sin outliers sigue una distribución

normal de media cero y desviación estándar σ_0, la mitad de los valores de $|R|$ es menor que $0{,}6745\,\sigma_0$, es decir, la mediana de $|R|$ vale $0{,}6745\,\sigma_0$. Por eso el cociente (3.10) estima σ_0 sin verse afectado por los outliers, mientras estos sean menos de la mitad de los píxeles.

Tercero, los píxeles cuyo residuo supera λ veces dicha estimación, con λ un umbral fijado para cada instancia del filtro, se reemplazan por el valor del filtro de mediana; el resto conserva su valor original. El resultado del filtro es

$$X_{out}(i,j) = \begin{cases} X_{med}(i,j), & |R(i,j)| > \lambda\,\hat{\sigma}_{SyP} \\ X(i,j), & \text{en otro caso} \end{cases} \tag{3.11}$$

De este modo, a diferencia de un filtro de mediana convencional, solo se modifican los píxeles anómalos y el resto de la matriz conserva su resolución.

En esta etapa el filtro se aplica con $X = I_{corr}$, inmediatamente después de la corrección de crosstalk, con ventana 5×5 y umbral $\lambda = 3$, para eliminar outliers tipo sal y pimienta (SyP); el resultado se denota I_{syp}. El mismo filtro se reutiliza más adelante, con otra ventana y otro umbral, para eliminar líneas impulsivas horizontales (Sección 3.1.4).

3.1.3. Corrección de Fondo por Línea de Barrido

Tras la corrección de crosstalk y la limpieza de outliers, se ajusta el nivel de cada fila para eliminar los desplazamientos de nivel entre líneas de barrido derivados del proceso de escaneo [8]. Para cada fila se asume que los píxeles de menor intensidad representan el fondo polimérico, ya que los CNTs aparecen como valores altos del gradiente de capacitancia. Se analiza el vector de intensidad de la fila i de I_{syp}, $\mathbf{f}_i = (I_{syp}(i,1), \ldots, I_{syp}(i,N))$, cuyo elemento j se denota $f_i(j)$, y se calcula un índice de variabilidad relativa:

$$\rho_i = \frac{\mathrm{MAD}(\mathbf{f}_i)}{P_{95}(\mathbf{f}_i) - P_5(\mathbf{f}_i)} \tag{3.12}$$

donde $\mathrm{MAD}(\mathbf{f}_i)$ es la desviación absoluta mediana de la fila, definida en (3.2), y $P_{95}(\mathbf{f}_i)$ y $P_5(\mathbf{f}_i)$ son sus percentiles 95 y 5. Este índice define de forma adaptativa el percentil q_i (en porcentaje) de píxeles utilizados para estimar el fondo, acotado entre el 25 % y el 45 %. El nivel de fondo b_i de la fila es la mediana de los píxeles cuyo valor no supera el percentil $P_{q_i}(\mathbf{f}_i)$, y se resta a la fila completa:

$$q_i = \mathrm{mín}\left(45,\ \mathrm{máx}\left(25,\ 40 - 20\,\rho_i\right)\right), \qquad b_i = \mathrm{med}\left\{f_i(j) : f_i(j) \le P_{q_i}(\mathbf{f}_i)\right\}, \qquad I_{fondo}(i,j) = f_i(j) - b_i \tag{3.13}$$

Como $\rho_i \ge 0$, el percentil nunca supera el 40 %, y la cota inferior solo se alcanzaría con

$\rho_i \geq 0{,}75$. Para las distribuciones de intensidad esperables en una fila (fondo con ruido y una fracción de CNTs de hasta la mitad de la fila), q_i queda aproximadamente entre el 32 % y el 39 %: el fondo de cada fila se estima con cerca del tercio más oscuro de sus píxeles. El percentil disminuye en las filas con una fracción alta de CNTs (distribución bimodal), en las que un percentil mayor incluiría píxeles de la red en la estimación del fondo.

3.1.4. Filtrado de Líneas Horizontales

Tras la corrección de fondo pueden permanecer tramos de línea de barrido cuyo nivel difiere del de las líneas vecinas, que se manifiestan como líneas impulsivas horizontales. Para eliminarlos se aplica nuevamente el filtro de la Sección 3.1.2 sobre I_{fondo}, con $X = I_{fondo}$, una ventana vertical de 5×1 ($a = 5$ filas por $b = 1$ columna) y umbral $\lambda = 2$; la estimación $\hat{\sigma}_{SyP}$ de (3.10) se recalcula para esta instancia. Con esta ventana, cada píxel se compara únicamente con los dos píxeles superiores y los dos inferiores de su misma columna: un tramo de línea desplazado respecto a sus vecinas produce un residuo grande y se reemplaza, mientras que una ventana horizontal no lo detectaría, porque los vecinos del píxel pertenecerían a la misma línea defectuosa. El resultado se denota I_{clean}.

3.1.5. Normalización

Finalmente, se aplica una normalización robusta entre los percentiles 1 y 99 de I_{clean}, $P_1 = P_1(I_{clean})$ y $P_{99} = P_{99}(I_{clean})$, calculados sobre todos los píxeles de la medición, para escalar los datos al intervalo $[0, 1]$ y estandarizar el contraste de cara a la binarización:

$$I_{seg}(i,j) = \text{máx}\left(0,\ \text{mín}\left(1,\ \frac{I_{clean}(i,j) - P_1}{P_{99} - P_1}\right)\right) \tag{3.14}$$

El 1 % de valores extremos de cada lado se satura en 0 y en 1, de modo que unos pocos píxeles no dominan la escala de los umbrales de binarización.

3.1.6. Segmentación Multiescala y Binarización

Esta etapa separa los píxeles pertenecientes a la red de nanotubos del fondo polimérico. Como los CNTs se encuentran a distintas profundidades dentro del polímero, modificando la señal captada por el microscopio, se requiere un método capaz de detectar tanto regiones superficiales como profundas, manteniendo la morfología y la continuidad espacial de la red, especialmente cuando se presentan cambios de profundidad.

La segmentación se construye como una combinación de tres binarizaciones complementarias sobre I_{seg}: local, global y regional, cuyas máscaras se integran por conjunción.

Binarización Local

La instancia local se basa en una umbralización adaptativa con núcleo gaussiano [6], implementada con las funciones `adaptthresh` e `imbinarize` de MATLAB. Para cada píxel se estima el fondo local $\mu_\sigma(i,j)$ como un promedio ponderado de las intensidades de su vecindad, calculado como la convolución de I_{seg} con un núcleo gaussiano bidimensional G_σ de desviación estándar σ, lo que asigna mayor peso a los vecinos cercanos al píxel central:

$$\mu_\sigma(i,j) = \sum_{|u-i|\le h} \sum_{|v-j|\le h} G_\sigma(u-i,\, v-j)\, I_{seg}(u,v), \qquad G_\sigma(\delta_u,\delta_v) = \frac{1}{Z}\exp\left(-\frac{\delta_u^2+\delta_v^2}{2\sigma^2}\right) \tag{3.15}$$

donde (δ_u, δ_v) es el desplazamiento, en píxeles, entre el vecino (u,v) y el píxel central; $h = \lceil 2\sigma \rceil$ es la semianchura del núcleo, que se trunca a $(2h+1)\times(2h+1)$ píxeles; y Z es la suma de los valores de la exponencial dentro de ese soporte, de modo que los pesos suman 1. Los vecinos que caen fuera de la matriz toman el valor del píxel más cercano del borde. En la binarización local, $\sigma = \sigma_L = 21$ px ($\approx 1{,}2$ μm), con un núcleo de 85×85 px. En `adaptthresh`, el parámetro `NeighborhoodSize` con estadístico gaussiano corresponde a esta desviación estándar, no al tamaño de una ventana.

Un píxel se clasifica como nanotubo en la máscara binarizada M_L, una matriz de $N \times N$ con valor 1 en los píxeles de red y 0 en los de fondo, si su intensidad supera la estimación local de fondo escalada por un factor γ, que depende del parámetro de sensibilidad $s \in [0,1]$ de `adaptthresh`:

$$M_L(i,j) = \begin{cases} 1, & I_{seg}(i,j) > \min\left(1,\ \gamma\, \mu_{\sigma_L}(i,j)\right) \\ 0, & \text{en otro caso} \end{cases}, \qquad \gamma = 1{,}6 - s \tag{3.16}$$

La relación $\gamma = 1{,}6 - s$ es la que aplica `adaptthresh` para objetos más brillantes que el fondo (opción `'ForegroundPolarity','bright'`), y el umbral se acota a 1, el máximo de I_{seg}.

Con $s = 0{,}55$, $\gamma = 1{,}05$: un píxel se clasifica como red si su intensidad supera en un 5 % la media ponderada de su vecindad. Una sensibilidad mayor reduce γ y aumenta el número de píxeles clasificados como red. El solapamiento entre las vecindades de píxeles vecinos asegura la continuidad en la captura de variaciones sutiles del gradiente. Esta binarización aporta alta definición pero introduce falsos positivos derivados de pequeñas variaciones eléctricas en el fondo, ya que su criterio es relativo: en zonas de fondo de baja intensidad, una diferencia del 5 % es pequeña en términos absolutos y el ruido la supera con facilidad.

Binarización Global

Como complemento, se realiza una binarización global basada en rangos de intensidad mediante una variación del método de Otsu [9] extendida a múltiples clases (`multithresh`). Dado que la formulación original de dos clases no captura los distintos grupos de intensidades de CNTs presentes en la imagen, se aplica un análisis multinivel que calcula $K = 6$ umbrales $t_1 < \ldots < t_6$. Con $t_0 = 0$ y $t_7 = 1$, los umbrales dividen los píxeles de la medición en siete clases según su valor de I_{seg}, $\Omega_\ell = \{(i,j) : t_\ell \leq I_{seg}(i,j) < t_{\ell+1}\}$ para $\ell = 0, \ldots, 6$ (la última clase incluye también los píxeles con $I_{seg} = 1$), y se eligen de modo que maximicen la varianza entre clases:

$$(t_1, \ldots, t_6) = \arg \max_{t_1 < \ldots < t_6} \sum_{\ell=0}^{K} \eta_\ell \left(\mu_\ell - \mu_{tot}\right)^2 \tag{3.17}$$

donde η_ℓ es la fracción de píxeles de la medición que pertenecen a la clase Ω_ℓ, μ_ℓ es la intensidad media de esos píxeles y μ_{tot} es la intensidad media de toda la medición. La función `multithresh` resuelve esta maximización sobre el histograma de I_{seg} con 256 niveles, por lo que los umbrales toman valores múltiplos de $1/255$. La primera clase, que agrupa los valores más bajos de I_{seg} y corresponde a las zonas más oscuras del fondo polimérico, se descarta de la máscara resultante M_G:

$$M_G(i,j) = \begin{cases} 1, & I_{seg}(i,j) \geq t_1 \\ 0, & \text{en otro caso} \end{cases} \tag{3.18}$$

A diferencia de las binarizaciones adaptativas, este umbral es absoluto y único para toda la medición, por lo que excluye las zonas de fondo de baja intensidad que la binarización local, por su criterio relativo, clasificaría como red.

Binarización Regional

La binarización regional M_R se construye con el mismo principio que la local, según (3.15) y (3.16) con la misma sensibilidad, pero empleando un núcleo significativamente mayor: $\sigma = \sigma_R = 51$ px (≈ 3 μm), truncado a 205×205 px, de modo que $M_R(i,j) = 1$ si $I_{seg}(i,j) > \text{mín}(1, \gamma\, \mu_{\sigma_R}(i,j))$. Su función es integrar la interacción entre las escalas global y local, y descartar regiones de ruido que las otras instancias no logran filtrar, especialmente en imágenes con mayor ruido de origen.

Integración de Máscaras

Cada binarización ofrece resultados consistentes pese a la heterogeneidad del dataset, pero presenta limitaciones complementarias: la local aporta definición a costa de ruido granular, la global secciona bien las capas de intensidad pero con baja definición, y la regional opera como filtro espacial intermedio. Las tres máscaras se integran mediante una conjunción lógica:

$$M_e = \mathcal{A}_{50}\Big(\mathcal{A}_{50}(M_G) \wedge M_R \wedge M_L\Big) \tag{3.19}$$

donde $\wedge$ es la conjunción lógica píxel a píxel (para dos máscaras M_1 y M_2, $(M_1 \wedge M_2)(i,j) = 1$ solo si $M_1(i,j) = 1$ y $M_2(i,j) = 1$). Solo los píxeles clasificados como red en las tres binarizaciones forman parte de la máscara final M_e. Adicionalmente, se impone una condición de tamaño mínimo por componente conexa. Una componente conexa es un conjunto máximo de píxeles de valor 1 en el que cualquier par puede unirse por una cadena de píxeles de valor 1 vecinos entre sí, considerando vecinos a los 8 píxeles que comparten un lado o una esquina. El operador $\mathcal{A}_{50}$ (`bwareaopen`) elimina, poniéndolas en 0, las componentes conexas de menos de 50 píxeles ($\approx 0{,}17\ \mu\text{m}^2$), y se aplica tanto a M_G antes de la conjunción como a la máscara resultante.

La elección de la conjunción de las tres escalas frente a otras alternativas basadas en estas máscaras se valida empíricamente sobre las 81 imágenes del dataset más adelante (Sección 4.1.4).

Activación Local de Respaldo

Cuando la cobertura de la máscara integrada, $c = \frac{1}{N^2}\sum_{i,j} M_e(i,j)$, es decir, la fracción de píxeles clasificados como red, cae por debajo del 15 %, se sustituye M_e por la binarización local, $M_e = \mathcal{A}_{50}(M_L)$, con los mismos parámetros empleados en la conjunción. Este mecanismo no introduce un método alternativo con parámetros propios sino que reutiliza el componente local del pipeline. La selección del umbral $0{,}15$ corresponde a un límite inferior de cobertura observado en el dataset cuando la conjunción opera con normalidad; del conjunto de 81 imágenes, solo una alcanza dicho umbral en la configuración del pipeline, y su comportamiento se discute más adelante.

3.1.7. Representaciones de Trabajo

A partir de la salida del pipeline se construyen cuatro representaciones que sirven como insumo común a los distintos grupos de descriptores: tres máscaras binarias derivadas de la segmentación y una imagen eléctrica en la escala original del canal eléctrico, utilizada por los descriptores que requieren sus valores sin normalizar.

- **Máscara estricta:** Contiene únicamente los píxeles clasificados como parte de red por el pipeline. Corresponde a M_e, definida en (3.19).

- **Máscara morfológica:** Aplica un cierre morfológico sobre la máscara estricta para unir estructuras y reparar discontinuidades [6]: $M_{mor} = (M_e \oplus B_r) \ominus B_r$, donde B_r es un elemento estructural en forma de disco de radio $r = 3$ px (`strel('disk',3)`, que MATLAB aproxima mediante una combinación de segmentos lineales), centrado en el origen. Para una máscara genérica M, la dilatación $M \oplus B_r$ pone en 1 todo píxel tal que el disco centrado en él toca al menos un píxel de valor 1 de M, lo que engrosa las estructuras y une las que están separadas por huecos estrechos; la erosión $M \ominus B_r$ deja en 1 solo los píxeles tales que el disco centrado en ellos queda completamente dentro de los píxeles de valor 1, lo que devuelve los bordes exteriores a su posición sin volver a abrir los huecos rellenados. Este radio repara granularidades y recupera continuidades a través de huecos de hasta aproximadamente $2r = 6$ px (≈ 350 nm), suficiente para evitar la sobresegmentación de regiones profundas sin destruir la morfología de la red.

- **Esqueleto:** Se obtiene mediante la función `bwskel` sobre la máscara morfológica. Esta función adelgaza cada componente conexa eliminando de forma iterativa píxeles de sus bordes, sin desconectarla ni abrir o cerrar huecos, hasta reducirla a líneas de 1 px de grosor que siguen su eje central y conservan su topología. Posteriormente se aplican cinco iteraciones de poda de píxeles mediante `bwmorph('spur', 5)`: en cada iteración se eliminan los puntos extremos del esqueleto, es decir, los píxeles con un solo vecino de valor 1 entre sus 8 vecinos. Así se recortan progresivamente las ramas y se eliminan las ramas espurias cortas, de hasta aproximadamente 5 px, que aparecen al esqueletizar bordes irregulares, evitando inflar artificialmente los descriptores basados en él. Las ramas largas pierden también hasta 5 px en su extremo libre. El esqueleto resultante se denota S.

- **Imagen eléctrica reconstruida I_B:** Canal eléctrico en su escala original, obtenido deshaciendo la normalización aplicada durante la corrección de crosstalk: al canal sin normalizar se le resta el mapa $\hat{I}_T$ de (3.6), reescalado por la MAD, $I_{corr,B} = I_{raw} - \mathrm{MAD}(I_{raw})\,\hat{I}_T$. Se aplica el filtro de eliminación de outliers SyP de la Sección 3.1.2 con $X = I_{corr,B}$, ventana 5×5 y $\lambda = 3$, cuyo resultado se denota $I_{syp,B}$. Para corregir artefactos de fondo entre filas sin afectar gradientes reales, se construye un perfil vertical 1D con la mediana de cada fila, $p(i) = \mathrm{med}\{I_{syp,B}(i,1), \ldots, I_{syp,B}(i,N)\}$, que se suaviza con la función `smoothdata` de MATLAB usando el método `rloess` con una ventana de $w = 50$ filas, lo que preserva la tendencia global de la imagen. Este método estima, para cada fila i, el valor suavizado $\tilde{p}(i)$ ajustando por mínimos cuadrados un polinomio de segundo grado a los valores de p de las w filas de la ventana centrada en i, y repite el ajuste reduciendo el peso de las filas con residuos grandes, de modo que los saltos abruptos entre filas no arrastren la tendencia $\tilde{p}$. La diferencia entre el perfil original y el suavizado se resta a la fila correspondiente:

$I_B(i,j) = I_{syp,B}(i,j) - (p(i) - \tilde{p}(i))$. A diferencia de I_{seg}, I_B no pasa por la corrección de fondo por línea, el filtrado de líneas horizontales ni la normalización; conserva por tanto las unidades nominales del canal eléctrico, de modo que sus valores son comparables dentro de una medición, pero no necesariamente entre sesiones de medición.

3.2. Extracción de Descriptores Morfológicos

Una vez construidas las máscaras que aíslan las regiones de nanotubos, se calculan los descriptores morfológicos propuestos. Por la diversidad de las características medidas, los descriptores se evalúan sobre diferentes representaciones de la red. Los diferentes descriptores se describen a continuación.

3.2.1. Descriptores de Distribución Espacial

Estos descriptores siguen la metodología propuesta en [4] y se calculan sobre la máscara morfológica simulando un escaneo con líneas aleatorias. La función de distribución de probabilidad (PDF) asociada a las mediciones discretas de espaciados y tamaños se construye mediante el ajuste lognormal de los datos.

Este ajuste, que surge de la naturaleza de la dispersión del nanorelleno, se establece como condición para la definición del calculo de los próximos descriptores, de la siguiente forma:

CNTD (uniformidad de espaciado). Se seleccionan aleatoriamente 100 líneas de barrido horizontales, con una semilla fija. Se mide la longitud de los tramos de polímero entre regiones de CNTs. A partir de la PDF construida con las medidas, se identifica el espaciado más frecuente η. El descriptor se obtiene integrando el área bajo la PDF en el rango $\eta \pm 20\,\%$:

$$\mathrm{CNTD} = \int_{0{,}8\eta}^{1{,}2\eta} f(s)\, ds \tag{3.20}$$

donde $f(s)$ es la PDF estimada. Valores altos del descriptor implican redes mas uniformemente espaciadas.

CNTA (aglomeración). Empleando las mismas líneas, se mide la longitud de los tramos de CNTs y se ajusta su PDF $g(\ell)$. El descriptor corresponde al área bajo la curva por encima de un umbral $\alpha = 2000$ nm, asociado a la longitud aproximada de dos SWCNTs [4]:

$$\mathrm{CNTA} = \int_{\alpha}^{\infty} g(\ell)\, d\ell \tag{3.21}$$