repara granularidades y recupera continuidades a través de huecos de hasta aproximadamente $2r = 6$ px (≈ 350 nm), suficiente para evitar la sobresegmentación de regiones profundas sin destruir la morfología de la red.

- **Esqueleto:** Se obtiene mediante la función `bwskel` sobre la máscara morfológica. Esta función adelgaza cada componente conexa eliminando de forma iterativa píxeles de sus bordes, sin desconectarla ni abrir o cerrar huecos, hasta reducirla a líneas de 1 px de grosor que siguen su eje central y conservan su topología. Posteriormente se aplican cinco iteraciones de poda de píxeles mediante `bwmorph('spur', 5)`: en cada iteración se eliminan los puntos extremos del esqueleto, es decir, los píxeles con un solo vecino de valor 1 entre sus 8 vecinos. De este modo se recortan progresivamente las ramas y se eliminan las ramas espurias cortas, de hasta aproximadamente 5 px, que aparecen al esqueletizar bordes irregulares, evitando inflar artificialmente los descriptores basados en él. Las ramas largas pierden también hasta 5 px en su extremo libre. El esqueleto resultante se denota S.

La Figura 3.7 muestra las matrices para la extracción de descriptores de la medición 0c-2.

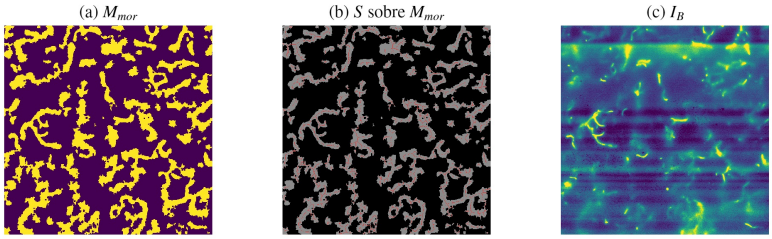


Figura 3.7: Matrices para la extracción de descriptores de la medición 0c-2. (a) Máscara morfológica M_{C}. (b) Esqueleto S (rojo) superpuesto a M_{C} (gris).

3.2. Extracción de Descriptores Morfológicos

Una vez construidas las matrices para la extracción de descriptores (Sección 3.1.7), sobre ellas se calculan 13 descriptores morfológicos por medición, agrupados según la característica de la red que cuantifican: distribución espacial, forma, orientación y conectividad. Cada descriptor resume una medición en un único valor escalar. Todos los descriptores se calculan con la función `calcular_descriptores`, desarrollada en MATLAB para este trabajo. La Tabla 3.2 resume los 13 descriptores, su símbolo, la matriz sobre la que se calculan y su unidad; los 13 valores de las 81 mediciones forman la matriz de descriptores X (Sección 3.3).

Tabla 3.2: Descriptores morfológicos calculados por medición.

Grupo	**Descriptor**	**Símbolo**	**Matriz**	**Unidad**
Distribución espacial	Uniformidad del espaciado	CNTD	M_{C}	adimensional
	Aglomeración	CNTA	M_{C}	adimensional
	Cociente aglomeración/uniformidad	CNTS	M_{C}	adimensional
Forma	Área media de las componentes	$\bar{A}$	M_{C}	$\mu\mathrm{m}^2$
	Desviación estándar del área	s_A	M_{C}	$\mu\mathrm{m}^2$
	Elongación media	$\bar{e}$	M_{C}	adimensional
	Tortuosidad media	$\bar{\tau}$	S	adimensional
Orientación	Orientación dominante	θ_d	M_{C}	grados
	Coherencia	κ	M_{C}	adimensional
Conectividad	Cobertura total	$c(M_{\mathrm{F}})$	M_{F}	adimensional
	Índice de percolación	P_{perc}	M_{C}	adimensional
	Longitud de red	L_S	S	μm
	Número de fragmentos	N_{C}	M_{C}	adimensional

Varias definiciones de esta sección se basan en las componentes conexas de una máscara, definidas en la Sección 3.1.6 con vecindad de 8 píxeles. Las componentes conexas de M_{C} se denotan $C_1, \ldots, C_{N_{\mathrm{C}}}$, donde N_{C} es su número, y $|C_k|$ es el número de píxeles de la componente C_k. Las longitudes se convierten a unidades físicas con la resolución espacial $\Delta \approx 58{,}6$ nm por píxel, y las áreas con Δ^2.

3.2.1. Descriptores de Distribución Espacial

Estos descriptores cuantifican cómo se reparte la red en el plano: si los CNTs se distribuyen con espaciados regulares o se concentran en aglomeraciones. Siguen la metodología propuesta en [4] y se calculan sobre la máscara morfológica M_{C}, simulando un escaneo con líneas aleatorias. Se seleccionan 100 filas de M_{C}, $r_1, \ldots, r_{100}$, cada una elegida con probabilidad uniforme entre las N filas mediante la función `randi` de MATLAB, con la semilla del generador de números aleatorios fijada en 42 (`rng(42)`); en consecuencia, la selección es la misma para todas las mediciones y puede repetir una fila. Cada fila es paralela a la línea de barrido del microscopio.

Sobre cada fila seleccionada se identifican los tramos de CNT, es decir, las secuencias máximas de píxeles contiguos de valor 1. La longitud de un tramo es su número de píxeles multiplicado por Δ. El espaciado entre dos tramos consecutivos de la misma fila es el número de píxeles de valor 0 que los separan, multiplicado por Δ. Los segmentos de valor 0 comprendidos entre el

borde de la matriz y el primer o el último tramo de la fila no se consideran espaciados, ya que no están delimitados por dos regiones de CNT. De este modo se obtienen, para cada medición, el conjunto de las longitudes de todos los tramos, $\{\ell_1, \ldots, \ell_{n_\ell}\}$, y el conjunto de todos los espaciados, $\{s_1, \ldots, s_{n_s}\}$, ambos en nanómetros.

Cada conjunto se describe mediante una distribución lognormal, cuya elección como modelo de la dispersión del nanorelleno se justifica en [4]. La función de densidad de probabilidad (PDF) lognormal de parámetros μ y σ y su función de distribución acumulada son

$$f(x;\mu,\sigma) = \frac{1}{x\,\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \qquad F(x;\mu,\sigma) = \Phi\left(\frac{\ln x - \mu}{\sigma}\right), \qquad x > 0 \tag{3.21}$$

donde Φ es la función de distribución acumulada de la distribución normal estándar, y μ y σ son la media y la desviación estándar de $\ln x$. Los parámetros se estiman a partir de los datos con la función `fitdist` de MATLAB (opción `'Lognormal'`): (μ_s, σ_s) para los espaciados y (μ_ℓ, σ_ℓ) para las longitudes. El ajuste se realiza solo si el conjunto contiene al menos 11 valores; en caso contrario, los descriptores que dependen de él quedan indefinidos para esa medición.

CNTD (uniformidad del espaciado). A partir de la PDF ajustada a los espaciados se identifica el espaciado más frecuente, η, que corresponde a la moda de la distribución lognormal, es decir, al valor en que f alcanza su máximo:

$$\eta = \exp\left(\mu_s - \sigma_s^2\right) \tag{3.22}$$

El descriptor es la probabilidad de que un espaciado se encuentre dentro del intervalo $\eta \pm 20\,\%$, es decir, el área bajo la PDF en ese intervalo:

$$\mathrm{CNTD} = \int_{0{,}8\eta}^{1{,}2\eta} f(s;\mu_s,\sigma_s)\,ds = F(1{,}2\eta;\mu_s,\sigma_s) - F(0{,}8\eta;\mu_s,\sigma_s) \tag{3.23}$$

Valores altos del descriptor indican que los espaciados se concentran alrededor del más frecuente, es decir, una red espaciada de forma más uniforme.

CNTA (aglomeración). Con la PDF ajustada a las longitudes de los tramos, el descriptor es la probabilidad de que un tramo supere el umbral $\alpha = 2000$ nm, asociado a la longitud aproximada de dos SWCNTs [4]:

$$\mathrm{CNTA} = \int_{\alpha}^{\infty} f(\ell;\mu_\ell,\sigma_\ell)\,d\ell = 1 - F(\alpha;\mu_\ell,\sigma_\ell) \tag{3.24}$$

Valores altos indican una mayor proporción de regiones de CNT con longitudes superiores a la de dos nanotubos, asociadas a aglomeraciones.

CNTS. Cociente entre los dos descriptores anteriores, definido cuando $\mathrm{CNTD} > 0$:

$$\mathrm{CNTS} = \frac{\mathrm{CNTA}}{\mathrm{CNTD}} \tag{3.25}$$

Valores altos indican una aglomeración alta de CNTs respecto a la uniformidad de su espaciado.

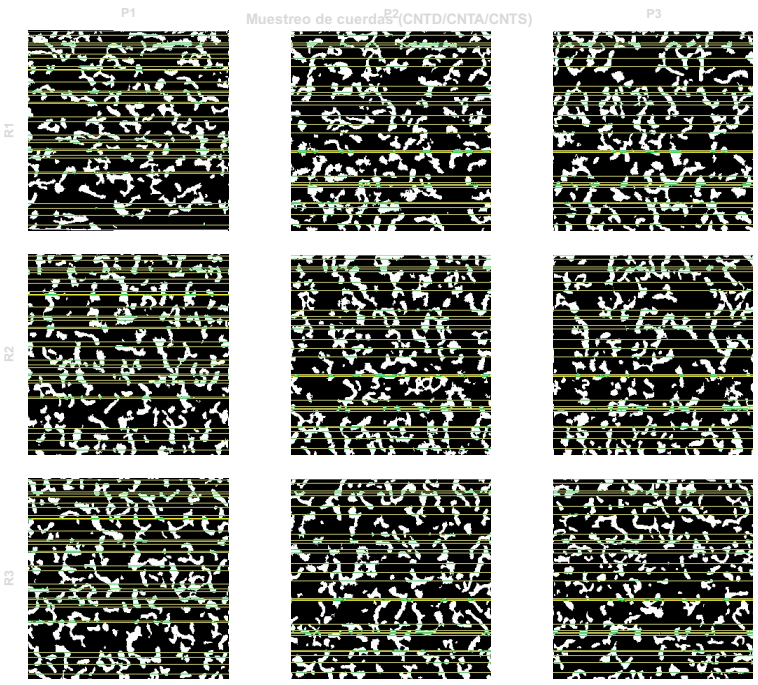


Figura 3.8: Muestreo de líneas para los descriptores de distribución espacial sobre el set 2b (15 V, 1 kHz; réplicas en filas, posiciones en columnas). Sobre la máscara morfológica M_{C} se trazan en amarillo las filas seleccionadas; los segmentos verdes marcan los tramos de CNT, cuyas longitudes alimentan CNTA, y los espacios entre ellos, los espaciados que alimentan CNTD.

Comparación de Binarizaciones para Reproducibilidad

Dado que CNTD, CNTA y CNTS se calculan a partir de una máscara binaria, su valor depende del método de binarización. Para evaluar si la dependencia de CNTS con el voltaje reportada en [4] se reproduce sobre este conjunto de datos, y si dicha reproducción depende del procesamiento propio, los tres descriptores se recalculan sobre las mismas mediciones con tres máscaras distintas. El procedimiento de cálculo de los descriptores y las 100 filas seleccionadas (misma semilla) son idénticos en los tres casos, de modo que la máscara es la única variable:

1. **Procesamiento propio:** la máscara morfológica M_{C} de este trabajo.
2. **Método de [4]:** sobre el canal eléctrico original E_0, escalado al intervalo $[0, 1]$ entre su mínimo y su máximo (`mat2gray`), se aplican una ecualización adaptativa de histograma con limitación de contraste (CLAHE, función `adapthisteq` con sus parámetros por defecto), un filtro de mediana de 3×3 (`medfilt2`) y un umbral igual al 75 % del valor máximo de la matriz resultante: los píxeles que lo superan toman el valor 1 y el resto el valor 0, tal como se describe en [4].
3. **Umbral de [4] sobre el preprocesamiento propio:** el mismo procedimiento del punto anterior, sin la ecualización CLAHE, aplicado a E_{seg} en lugar de E_0. Con ello se aísla el efecto de la binarización, manteniendo fijo el preprocesamiento.

Se compara CNTS en función del voltaje a 10 Hz, la única frecuencia comparable con [4], para las tres máscaras.

3.2.2. Descriptores de Forma

Estos descriptores caracterizan el tamaño y la forma de las regiones de la red, y cuánto se desvían sus estructuras de una trayectoria recta. Se calculan sobre las componentes conexas C_k de M_{C} con la función `regionprops` de MATLAB [6], salvo la tortuosidad, que se calcula sobre el esqueleto S.

Área media y desviación estándar del área. El área de cada componente es su número de píxeles multiplicado por el área de un píxel, $A_k = |C_k|\,\Delta^2$, expresada en $\mu\mathrm{m}^2$. Los descriptores son la media y la desviación estándar muestral de las áreas de las N_{C} componentes:

$$\bar{A} = \frac{1}{N_{\mathrm{C}}} \sum_{k=1}^{N_{\mathrm{C}}} A_k, \qquad s_A = \sqrt{\frac{1}{N_{\mathrm{C}} - 1} \sum_{k=1}^{N_{\mathrm{C}}} \left(A_k - \bar{A}\right)^2} \tag{3.26}$$

Elongación media. A cada componente se asocia la elipse que tiene sus mismos momentos centrales de segundo orden [6]; a_k y b_k son las longitudes de los ejes mayor y menor de esa elipse, en píxeles (parámetros `MajorAxisLength` y `MinorAxisLength` de `regionprops`). El descriptor es el promedio, sobre las N_{C} componentes, del cociente entre ambos ejes:

$$\bar{e} = \frac{1}{N_{\mathrm{C}}} \sum_{k=1}^{N_{\mathrm{C}}} \frac{a_k}{b_k} \tag{3.27}$$

Un cociente igual a 1 corresponde a una componente sin dirección preferente, como un disco, y valores mayores, a componentes alargadas.

Tortuosidad media. La tortuosidad compara la longitud de una estructura medida a lo largo de su trayectoria con la distancia en línea recta entre sus extremos. Se calcula sobre las componentes conexas del esqueleto S, con vecindad de 8 píxeles. En cada componente se identifican sus puntos extremos, es decir, los píxeles con un único vecino de valor 1 (función `bwmorph` con la opción `'endpoints'`), y se mide la distancia geodésica entre ellos, definida como la longitud del camino más corto que los une recorriendo únicamente píxeles del esqueleto, con pasos de longitud 1 entre píxeles que comparten un lado y $\sqrt{2}$ entre píxeles que comparten una esquina (función `bwdistgeodesic` con la opción `'quasi-euclidean'`).

El par de extremos más alejados se identifica en dos pasos: primero se calcula la distancia geodésica desde un extremo cualquiera de la componente y se toma el extremo más lejano, a; después se calcula la distancia geodésica desde a y se toma el extremo más lejano, b. Este procedimiento identifica el par de extremos con la mayor distancia geodésica cuando la componente no contiene ciclos. La longitud de arco de la componente es la distancia geodésica entre a y b, $L^{(\text{arco})}$, y la cuerda es la distancia euclidiana entre ellos, $L^{(\text{cuerda})} = \sqrt{(x_a - x_b)^2 + (y_a - y_b)^2}$, ambas en píxeles. Solo se consideran las componentes con al menos 8 píxeles, al menos dos extremos y una longitud de arco de al menos 15 píxeles ($\approx 0{,}9$ μm), de modo que los fragmentos cortos, cuya tortuosidad es poco representativa, no intervienen. Si M es el número de componentes que cumplen estas condiciones, el descriptor es

$$\bar{\tau} = \frac{1}{M} \sum_{m=1}^{M} \frac{L_m^{(\text{arco})}}{L_m^{(\text{cuerda})}} \tag{3.28}$$

Cuantifica cuánto se desvían las estructuras de la red respecto de una trayectoria recta entre sus extremos: valores cercanos a 1 corresponden a estructuras casi rectas, y valores mayores, a estructuras más sinuosas.

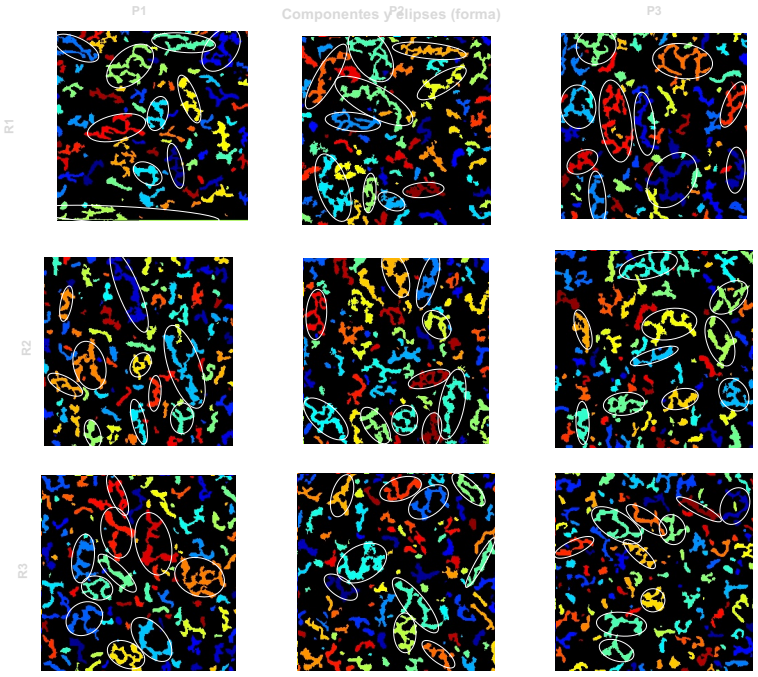


Figura 3.9: Componentes conexas de la máscara morfológica M_{C} del set 2b, coloreadas por etiqueta, con las elipses de igual momento de segundo orden superpuestas sobre las mayores. Los ejes de cada elipse definen la elongación de la componente, y su número de píxeles, el área.

3.2.3. Descriptores de Orientación

Estos descriptores cuantifican si las estructuras de la red siguen una dirección preferente. La orientación se evalúa mediante el tensor de estructura [6], calculado sobre la máscara morfológica M_{C}. Como el gradiente de una máscara binaria solo es distinto de cero en los bordes y cambia de forma abrupta, la máscara se suaviza primero con un núcleo gaussiano de desviación estándar $\sigma_d = 2$ px, según (3.14), con la función `imgaussfilt`, lo que produce una matriz de valores continuos $Q = G_{\sigma_d} * M_{\mathrm{C}}$, donde $*$ denota la convolución. Sobre Q se calculan las derivadas $\partial Q/\partial x$ y $\partial Q/\partial y$ por diferencias centrales, según (3.3), y los productos de las derivadas se promedian localmente con un segundo núcleo gaussiano, de desviación estándar $\sigma_i = 8$ px:

$$J_{xx} = G_{\sigma_i} * \left(\frac{\partial Q}{\partial x}\right)^2, \qquad J_{yy} = G_{\sigma_i} * \left(\frac{\partial Q}{\partial y}\right)^2, \qquad J_{xy} = G_{\sigma_i} * \left(\frac{\partial Q}{\partial x}\,\frac{\partial Q}{\partial y}\right) \tag{3.29}$$

La escala σ_d se ajusta al grosor de las estructuras de la red, y σ_i, a la escala sobre la que se promedia su dirección. Las tres componentes se suman sobre los píxeles de la red, es decir, sobre los píxeles de valor 1 de M_{C}, y forman el tensor de estructura de la medición:

$$T = \begin{pmatrix} T_{xx} & T_{xy} \\ T_{xy} & T_{yy} \end{pmatrix}, \qquad T_{xx} = \sum_{M_{\mathrm{C}}(i,j)=1} J_{xx}(i,j), \quad T_{yy} = \sum_{M_{\mathrm{C}}(i,j)=1} J_{yy}(i,j), \quad T_{xy} = \sum_{M_{\mathrm{C}}(i,j)=1} J_{xy}(i,j) \tag{3.30}$$

Los valores propios de T, $\xi_1 \geq \xi_2 \geq 0$, son

$$\xi_{1,2} = \frac{T_{xx} + T_{yy}}{2} \pm \frac{1}{2}\sqrt{(T_{xx} - T_{yy})^2 + 4T_{xy}^2} \tag{3.31}$$

El vector propio asociado a ξ_1 indica la dirección en que la intensidad de Q varía más, que es perpendicular a las estructuras; la dirección de las estructuras es la perpendicular a esta. Los descriptores se calculan solo si M_{C} contiene más de 10 píxeles de valor 1 y $T_{xx} + T_{yy} > 0$.

Orientación dominante. Ángulo de la dirección de las estructuras, obtenido al sumar 90° al ángulo del vector propio asociado a ξ_1 y expresado en el intervalo $[0^\circ, 180^\circ)$:

$$\theta_d = \left(\frac{1}{2}\,\mathrm{atan2}\,(2T_{xy},\ T_{xx} - T_{yy}) + 90^\circ\right) \text{ mód } 180^\circ \tag{3.32}$$

donde $\mathrm{atan2}(v, u)$ es el ángulo del vector (u, v) respecto del eje x, en el intervalo $(-180^\circ, 180^\circ]$. El ángulo se mide desde el eje x, es decir, desde la dirección de la línea de barrido, hacia el sentido creciente del índice de fila i; como las filas crecen hacia abajo en la imagen, el ángulo crece en sentido horario sobre la imagen.

Coherencia. Relación entre la diferencia y la suma de los valores propios:

$$\kappa = \frac{\xi_1 - \xi_2}{\xi_1 + \xi_2} \tag{3.33}$$

Valores próximos a 1 indican una alta alineación direccional, y valores próximos a 0, una red isótropa. La coherencia delimita además la validez de la orientación dominante: en una red casi isótropa no existe una dirección preferente bien definida, por lo que θ_d solo es significativa cuando κ es apreciable.

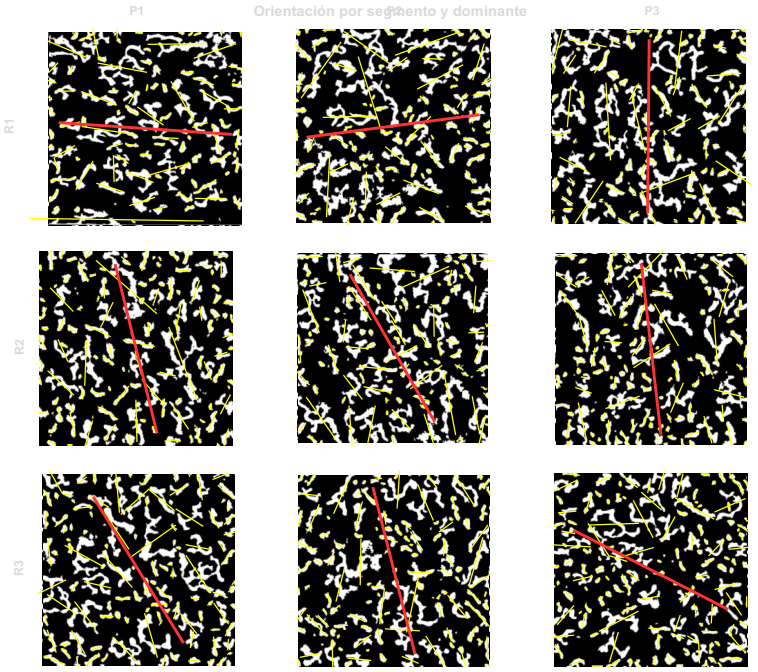


Figura 3.10: Orientación de la red para las nueve mediciones del set 2b. Cada barra amarilla indica la orientación de una componente de M_{C}, obtenida con el tensor de estructura sumado sobre los píxeles de esa componente, y la barra roja marca la orientación dominante θ_d de la medición.

3.2.4. Descriptores de Conectividad y Topología

Estos descriptores evalúan la red como un todo: qué fracción de la superficie ocupa, en qué medida forma una estructura continua y cuán extensa es.

Cobertura total. Fracción de píxeles clasificados como red, $c(M_{\mathrm{F}})$, definida en (3.19). Se calcula sobre la máscara final y no sobre M_{C}, para no incluir los píxeles que agrega el cierre morfológico.

Índice de percolación. Cociente entre el área de la componente conexa más grande de M_{C} y el área total ocupada por todas las componentes:

$$P_{\mathrm{perc}} = \frac{\max_k |C_k|}{\sum_{k=1}^{N_{\mathrm{C}}} |C_k|} \tag{3.34}$$

Cuantifica la dominancia de la componente mayor sobre la red segmentada: valores cercanos a 1 indican que casi toda la red pertenece a una sola estructura conexa. El índice no evalúa si esa componente atraviesa la medición de un borde a otro.

Longitud de red. Longitud total del esqueleto S, obtenida al sumar las distancias entre sus píxeles vecinos:

$$L_S = \left(n_o + \sqrt{2}\, n_d\right) \Delta \tag{3.35}$$

donde n_o es el número de pares de píxeles de valor 1 de S que comparten un lado, y n_d, el número de pares que comparten solo una esquina y cuyos dos vecinos comunes tienen valor 0. Esta condición evita contar dos veces un mismo recorrido: si dos píxeles diagonales están unidos también a través de un vecino común, el recorrido ya está contado por los pasos horizontal y vertical. L_S se expresa en μm.

Número de fragmentos. Número de componentes conexas de M_{C}, N_{C}, calculado con la función `bwconncomp` con vecindad de 8 píxeles. Un número alto indica una red dividida en muchas regiones aisladas.

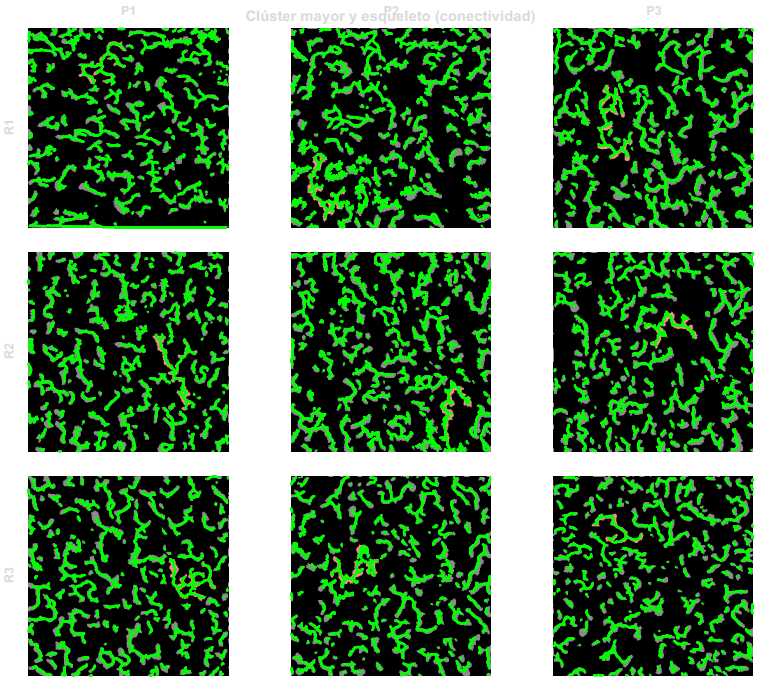


Figura 3.11: Análisis de conectividad sobre el set 2b: el esqueleto S (verde), base de la longitud de red, superpuesto a la máscara morfológica M_{C} (gris).

3.3. Análisis de Datos y Aprendizaje Automático

A partir de los 13 descriptores extraídos por medición se construye la matriz de descriptores X, de 81×13, que constituye el insumo del análisis. Este se organiza en dos etapas. La primera es un análisis exploratorio no supervisado que caracteriza la estructura interna del espacio de descriptores y su redundancia. La segunda corresponde a los modelos supervisados: el análisis predictivo de regresión hacia la eficacia de apantallamiento (SE), que constituye el objetivo central del trabajo.